

باسمه تعالی



دانشگاه صنعتی شریف

دانشکده مهندسی برق

درس علوم اعصاب محاسباتی مقدماتی

بررسی رفتار نوروهای پیچیده Primary Visual Cortex گربه

مبتنی بر دیتای تهاجمی

بهراد منیری

معید جمالزاده

استاد

دکتر حمید کربلایی آقاجان

زمستان ۱۳۹۶

## مقدمه و توضیحات درباره فایل‌ها

فایل متلب اصلی این تمرین HW01\_Moniri\_95109564.m است که تمام بخش‌های تمرین را اجرا می‌کند.

در بخش‌های ۳ و ۴ تمرین باید نتایج را برای تمام نوروها گزارش می‌کردیم، تمامی نتایج در دو فایل STA.pdf و STC.pdf ضمیمه شده‌اند و از آوردن مجدد این جداول در گزارش خودداری شده است.

برای آسان‌تر شدن تصحیح این تمرین، همان‌طور که از آقای مدیرشانه‌چی کسب اجازه شد، فایل متلب اصلی نتایج را تنها برای یک نورو محاسبه می‌کند و برای محاسبه جواب‌ها برای تمام نوروها فایل fullresults.m ساخته شده است اما اجرای آن به مدت زیادی زمان نیاز دارد.

خروجی اصلی کد در فایل HW01\_Moniri\_95109564.m، یک داده ساختار به نام neurons است که تمامی نتایج اصلی این کد در آن ذخیره می‌شوند. کد ما به طور کامل این داده ساختار را تولید می‌کند اما برای اطمینان بیشتر یک نسخه از آن در <http://ee.sharif.ir/~bemoniri/fullneurons.mat> بارگذاری شده است.

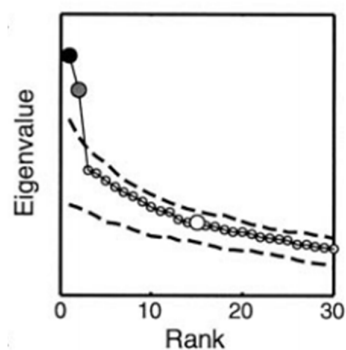
## سوال ۱

هدف این مقاله نورون‌های بینایی و بررسی این موضوع است که این نورون‌های به تحریک‌های مختلف چگونه پاسخ می‌گویند. پژوهش‌گران قصد دارند که تحریک‌های پیچیده را به تعدادی feature ساده تجزیه کنند و بررسی کنند که هر کدام از این feature چه تاثیری در پاسخ نورن دارد. قبل از این مقاله مطالعه زیادی بر روی نورون‌هایی با رابطه تحریک-پاسخ خطی به روش Reverse Correlation یا STA، اکثرا بر روی نورون‌های Early Visual Pathway که تا حدی خوبی خطی هستند انجام شده بود اما نورون‌های Visual Cortex اکثرا غیرخطی هستند و این نوع روش‌ها برای تحلیل آن‌ها مناسب نیست. پژوهشگران این مقاله با استفاده از روش Spike Triggered Correlation این تحلیل را بر روی نورون‌های غیرخطی Visual Cortex انجام دهند.

## سوال ۲

نورون‌های پیچیده نورن‌هایی هستند که رابطه تحریک-پاسخ آن‌ها خطی نیست. بیشتر نورون‌های Visual Cortex غیرخطی، پیچیده، هستند. برای بررسی غیرخطی بودن نورون از این استفاده شده که روش STA در نورون‌های خطی باید بتواند درصد بالایی از تحریک‌های مناسب که باعث اسپایک می‌شوند را از تحریک‌های نامناسب جدا کند.

## سوال ۳




شکل ۱

در روش Spike Triggered Correlation، در فضای بعد-بالای تحریک‌ها، که در این آزمایش خاص یک فضای ۲۵۶ بعدی است، جهت‌هایی را پیدا می‌کنیم که تصویر داده‌ها بر این جهت‌ها بیشینه واریانس را داشته باشند تا داده‌ها به نحو بهتری از یکدیگر جدا شوند. انتظار داریم تحریک‌های منجر به اسپایک توزیع متفاوتی نسبت به تحریک‌های دیگر داشته باشند. در این روش این تفاوت را با تفاوت در واریانس می‌سنجیم.

برای پیدا کردن این جهت‌ها، ابتدا ماتریس کورلیشن را برای متغیرهای تصادفی  $[X_1, X_2, X_3, \dots, X_{256}]$  پیدا می‌کنیم که  $X_i$  مولفه  $i$ ام بردار تحریک است. مقادیر ویژه این ماتریس را پیدا می‌کنیم و بردار ویژه‌های مربوط به هر یک از این مقادیر ویژه را پیدا می‌کنیم. مقادیر ویژه‌ای که به حد محسوسی از سایر مقادیر ویژه بزرگتر است را انتخاب می‌کنیم، پژوهشگران این کار را با بازه اطمینان  $mean \pm 5.2STD$  انجام داده‌اند و مقادیر ویژه خارج این بازه را Significant در نظر گرفتند. شکل ۱. بردارویژه‌های مربوط به این مقادیر ویژه را پیدا می‌کنیم و تصویر بردارهای تحریک را بر روی این بردارها پیدا می‌کنیم.

## سوال ۴



شکل ۲

برای بررسی اعتبار یافته‌هایمان، برای هر نورون به تعداد اسپایک‌های واقعی‌اش زمان رندوم تولید می‌کنیم و توزیع تصویر بردارهای تحریک منجر به اسپایک واقعی و بردارهای تحریک مربوط به زمان رندوم با همدیگر مقایسه می‌کنیم. این دو توزیع باید به طور معناداری با یکدیگر تفاوت داشته باشند و بتوانیم با آن تعداد مناسبی از تحریک‌های منجر به اسپایک را از تحریک معمولی جدا کنیم. شکل ۲.

## سوال ۵

در آزمایش به گربه‌های بالغ ۳۲۷۶۵ فریم عکس با شانزده نوارهای سیاه و سفید با فرکانس تقریباً ۶۰ هرتز نمایش داده شده است. فرض شده برای هر اسپایک شانزده فریم گذشته تاثیر داشته‌اند بنابراین تحریک مربوط به هر اسپایک با یک بردار ۲۵۶ بعدی قابل نمایش است. واریانس مشخص کننده هر feature در تحریک فرض شده است. یک feature با واریانس به طور معنا دار بزرگتر یا کوچکتر از واریانس داده‌های کنترل به طور مستقیم با اسپایک زدن نورون ارتباط دارد. در تحلیل پژوهشگران برای اغلب نورون‌ها دو بردار ویژه غالب به دست آمد. برای تعداد اندکی از نورون‌ها تنها یک بردار ویژه غالب به دست آمد. این رفتار این نورون‌ها شباهت زیادی با نورون‌های خطی داشت.

به طور کلی در این پروژه هدف ما بررسی و باز تولید نتایج این مقاله است.

## بخش دوم - آشنایی با دیتاست


### سوال ۱

در فایل‌های مربوط به هر نورون، چندین فایل با فرمت sa0 و log وجود دارد. فایل‌ها با نام msq1D.sa0\* شامل زمان اسپایک آن نورون خاص در باز نمایش دنباله تحریک به گربه هستند. ممکن است برای هر نورون چندین بار آزمایش انجام شده باشد بنابراین چند فایل با این فرمت خواهیم داشت. در header این فایل‌ها اطلاعاتی در مورد سیگنالی که به عنوان اسپایک در نظر گرفته شده مانند ThreshPeakHigh، ThreshValleyHigh و نوع الکتروود وجود دارد.

### سوال ۲

در فایل‌های log نیز اطلاعات تحریک مانند فرکانس نمایش فریم‌های فیلم، RefreshRate و نام تست وجود دارد. در این بخش تابعی به نام Func\_ReadData نوشته‌ایم که در ورودی نام یک نورون را به صورت رشته می‌پذیرد و در دیتاست فولدر مربوط به آن نورون خاص را پیدا می‌کند. این تابع تمام فایل‌های msq1D.sa0\* مربوط به آن نورون را داده‌های زمان اسپایک مربوط به هر آزمایش و هدر فایل‌ها را در یک struct مرتب کرده و Spike Count Rate نورون در هر آزمایش را محاسبه می‌کند و داده ساختار مذکور را به عنوان خروجی باز می‌گرداند.

### سوال ۳



شکل ۳

در تابع Func\_ReadData مقدار میانگین Spike Count Rate را برای هر آزمایش روی نورون ورودی تابع محاسبه کردیم.

$$\text{Spike Count Rate} = \frac{\text{Number of Spikes}}{\text{Time of the Experiment}}$$

حال برای هر نورون متوسط spike count rate آزمایش‌های مختلف را محاسبه کرده و به عنوان Average Spike Count نورون گزارش می‌کنیم. شکل ۳ هیستوگرام Average Spike Count نورون‌های مورد بررسی است.

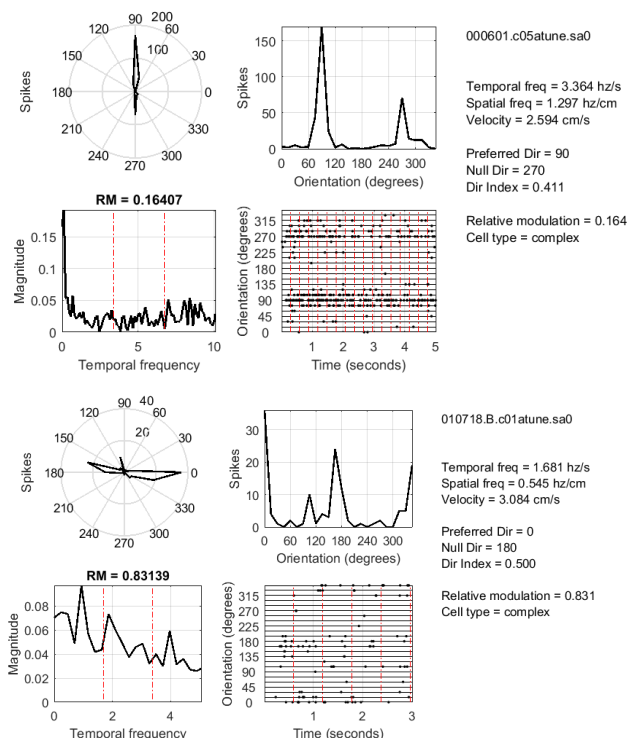
000413.b03	000413.b04	000413.b05	000418.a01	000420.b02	000524.c01	000907.f07
------------	------------	------------	------------	------------	------------	------------

جدول ۱

#### سوال ۴

تابع Func\_StimuliExtraction به عنوان ورودی بردار زمان‌های اسپایک را گرفته و در خروجی ماتریسی از تحریک‌هایی که منجر به اسپایک‌ها شده‌اند را برمی‌گرداند.

#### سوال ۵



شکل ۴

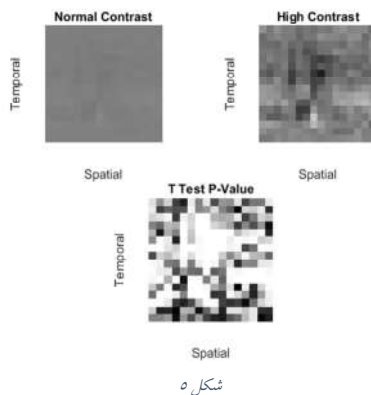
تحریک msq1D که در ادامه با آن کلنجار خواهیم رفت برای هر آزمایش نورون که جهت بیشینه تحریک همان نورون نمایش داده شده‌است. همان‌گونه که در اسلایدهای درس نیز مشاهده کردیم، برای به دست آوردن این جهت، یک تحریک خاص را در جهت‌های مختلف به گربه نمایش دادند و اسپایک‌های نورون را در زاویه‌های مختلف ثبت کردند. شکل ۴ نمونه‌ای از داده‌های تیم پژوهش برای یک نورون خاص است. همان‌طور که دیده می‌شود اگر تحریک زاویه 90 درجه داشته باشد، این نورون بیشترین spike rate را خواهد داشت. (Preferred Dir = 90)

این موضوع در نمودار Raster رسم شده نیز به خوبی قابل مشاهده است.

## بخش سوم – بررسی با روش کلاسیک Spike- Triggered Average

در ابتدا بررسی‌های خود را روی نورون 000601.c05 انجام می‌دهیم و در سوال آخر این بخش، روش خود را بر روی دیگر نورون‌ها تکرار کرده و نتایج را گزارش می‌کنیم.

### سوال ۱



شکل ۵

در این بخش با استفاده از روش Spike Triggered Average شکل تخمینی Receptive Field ها را به دست می‌آوریم. برای این کار به کمک تابع Func\_StimuliExtraction برای هر اسپایک نورون، ماتریس  $16 \times 16$  تحریک را به دست می‌آوریم. از این تحریک ها که منجر به اسپایک شدند را میانگین می‌گیریم.

برای نورون مشخص شده با این روش تخمین مان از Receptive Field را به دست آورده و در شکل ۵ نمایش می‌دهیم.

شکل بالا – چپ، شکل واقعی به دست آمده برای Receptive Field است. در شکل بالا – راست، Contrast تصویر را افزایش دادیم تا شکل با وضوح بیشتری دیده شود.

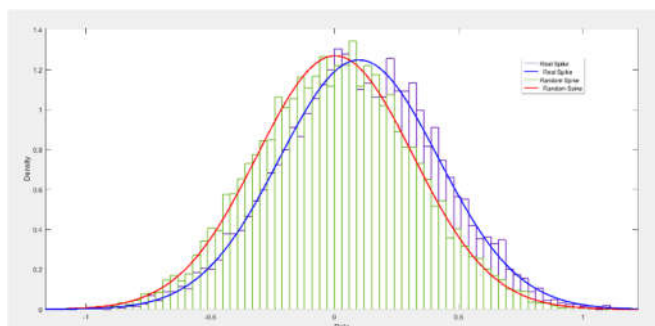
### سوال ۲\*

در این بخش آزمون فرضیه (T-Student) را بر روی Receptive Field اعمال می‌کنیم تا ببینیم کدام درایه ها تفاوت معناداری با صفر دارند.

Null-Hypothesis ما این است که سِمپل‌ها از جامعه‌ای با میانگین صفر آمده باشند. ماتریسی تشکیل می‌دهیم و در هر درایه ماتریس 1-PValue آن درایه را قرار می‌دهیم. ماتریس مذکور را به کمک تابع imshow نمایش می‌دهیم. به شکل ۳ مراجعه کنید.

P-Value یک آزمون فرضیه به این معناست که اگر فرضیه درست باشد با چه احتمالی سِمپل ما و نتایج extreme تر می‌توانسته از آن توزیع بیاید.

### سوال ۳



شکل ۶

حال یک جهت در فضای 256 بعدی یافته‌ایم، انتظار داریم اگر Correlation بردار تحریک با این جهت از حدی بیشتر شود یا به عبارت دیگر تصویر بردار تحریکمان در این راستا از حدی بیشتر باشد، اسپایک رخ دهد. برای بررسی این موضوع یک بار هیستوگرام ضرب داخلی تحریک‌های منجر به اسپایک را رسم می‌کنیم. سپس تعدادی زمان تصادفی با توزیع یونیفورم تولید کرده و


ضرب داخلی بردار تحریک مربوط به آنها را بر روی بردار میانگین حساب کرده و هیستوگرام آن را نیز رسم می‌کنیم. شکل ۶.

توزیع‌های به دست آمده را با توزیع نرمال تقریب می‌زنیم. مشاهده می‌شود که میانگین این دو دسته داده تا حد زیادی برابر است در حالی که انتظار داشتیم هیستوگرام مربوط به اسپایک واقعی به شدت با هیستوگرام مربوط به Random Spike تفاوت کند. این نزدیک بودن دو هیستوگرام نشان می‌دهد که روش STA حل مناسبی برای این مساله نیست زیرا هدف ما از این محاسبات این است که بتوانیم عددی پیدا کنیم که اگر ضرب داخلی بردار تحریک و بردار میانگین از آن بیشتر باشد بتوانیم بگوییم با احتمال زیادی اسپایک زده خواهد در سوال ۵ این حد را برای روش STA به دست می‌آوریم و نشان می‌دهیم که این روش نمی‌تواند با دقت خوبی اسپایک را پیش‌بینی کند.

#### سوال ۴\*

در بخش قبل دو متغیر تصادفی ضرب داخلی بردارهای منجر به اسپایک بر روی STA (به نام زتا) و ضرب داخلی تحریک مربوط به اسپایک رندوم (به نام رندم زتا) را معرفی کردیم. در این بخش بر روی داده‌های بخش قبل آزمون فرضیه T-Student تست را برای فرضیه برابر بودن مقدار چشم‌داشتی دو متغیر تصادفی مذکور اعمال می‌کنیم. برای نورون مشخص شده احتمال اینکه با وجود این برآمد ها، داده‌ها از دو توزیع با میانگین برابر آمده باشند برابر  $10^{-43} \times 6$  به دست می‌آید! این موضوع نشان می‌دهد که روش STA آن قدر که به نظر می‌آید بد نیست! آزمون ttest فرضیه ما که برابر بودن میانگین دو توزیع بود را رد کرد.

#### سوال ۵



در این بخش می‌خواهیم برای هر نورون ناحیه ON و OFF تعیین کنیم به این معنا که  $\zeta_0$  ای را پیدا کنیم که اگر ضرب داخلی یک بردار تحریک و میانگین از  $\zeta_0$  بیشتر شد بگوییم این نورون اسپایک خواهد زد.

برای به دست آوردن این حد هیستوگرامی شبیه هیستوگرام بخش چهار را برای هر نورون تولید می‌کنیم و توزیع آنها را همانند شکل ۷ با توزیع نرمال تخمین می‌زنیم. نقطه تلاقی دو تابع را به دست می‌آوریم و بازه ای را پیدا می‌کنیم که pdf توزیع تحریک منجر به اسپایک از pdf مربوط به داده‌های تصادفی مقدار بزرگتری داشته باشد. این ناحیه‌ها را ناحیه ON نورونمان در نظر می‌گیریم.

شکل چهار هیستوگرام مربوط به نورون مورد نظر است که با توزیع گاوسی تقریب زده شده‌اند. خط زرد جداکننده ناحیه ON و OFF نورون است. اگر ضرب داخلی یک تحریک با بردار میانگین در سمت راست این خط قرار بگیرد می‌گوییم تحریک منجر به اسپایک می‌شود و اگر در سمت چپ قرار بگیرد می‌گوییم این تحریک منجر به اسپایک نخواهد شد.

این روش برای این نورون خاص 55.93% از تحریک‌های منجر به اسپایک را درست دسته‌بندی می‌کرد.

## سوال ۶

به دلیل حجم بالای این جدول، آن را به صورت ضمیمه در فایل STA.pdf آورده‌ایم.

## سوال ۷

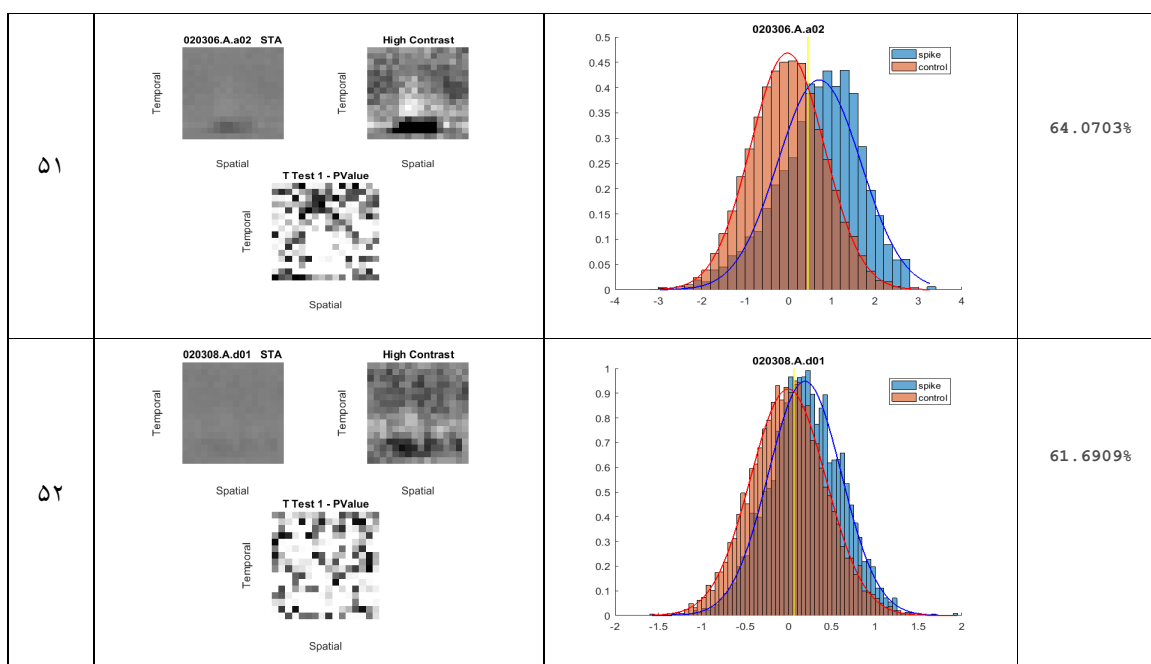
در این Receptive Field ها تا حدی پترن‌های معنادار دیده می‌شود. برای مثال به نظر می‌رسد نورون ۲۳ به تغییر رنگ صفحه از سیاه به سفید حساس است یا نورون ۴۹ به تغییر رنگ دو قطعه مختلف از تصویر به طور مشترک حساسیت نشان می‌دهد. نورون ۳۷ به این موضوع پاسخ می‌دهد که تعدادی از نوار ها برای مدتی سفید بمانند و ناگهان سیاه شوند. نورون های ۵۹، ۵۱ و ۴۲ نیز پترن‌های جالبی دارند.

این پترن ها بیشتر در نورون هایی یافت می‌شود که درصد تشخیص درست اسپایک در آنها از 59% بیشتر است.

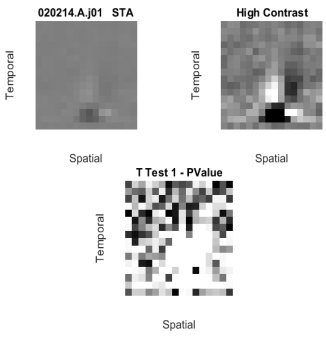
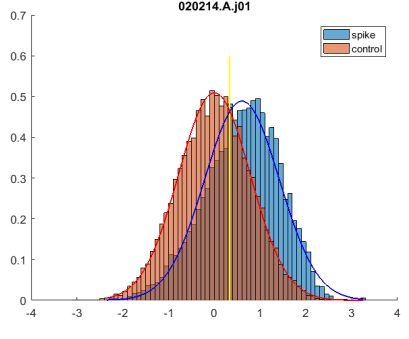
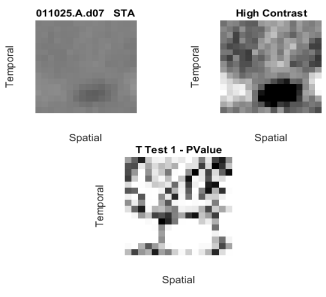
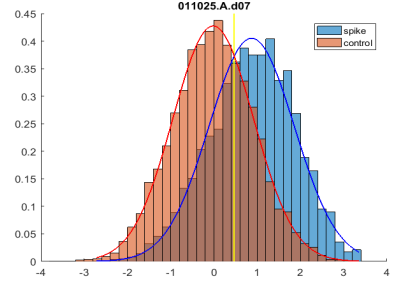
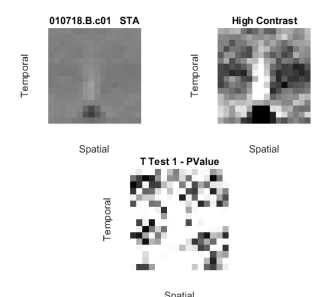
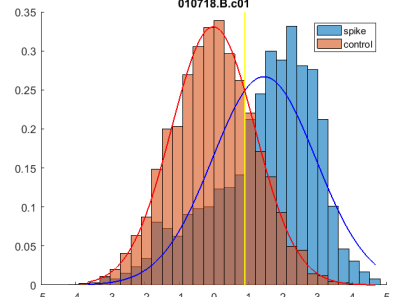
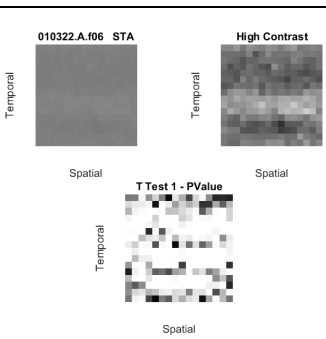
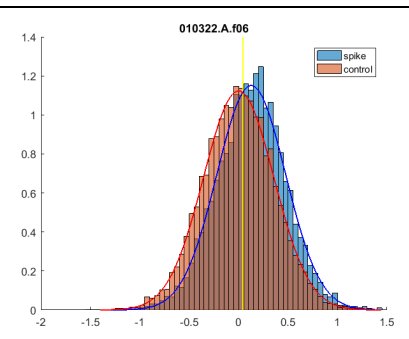
ادعای مقاله مبنی بر ساده نبودن این نورون‌ها، حداقل تعداد زیادی از آنها، منطقی به نظر می‌رسد زیرا روش STA به طور میانگین برای نورون‌های مختلف ۵۶ درصد از اسپایک‌ها را درست تشخیص می‌دهد. به جز چند نورون خاص که اتفاقاً در Receptive Field آنها پترن‌های جالبی نیز دیده میشود و نام آنها در بالا ذکر شده برای بقیه نورون ها نتوانستیم با روش‌های خطی سیستمی مناسب برای پیش‌بینی اسپایک طراحی کنیم. میانگین تصویر تحریک منجر به اسپایک ها در صفر اتفاق افتاده و توزیع تصویر تحریک‌های منجر به اسپایک و توزیع تصویر مربوط به زمان‌های مربوط اکثراً روی همدیگر افتاده‌اند و با این روش از یکدیگر جدا نشده‌اند.

چند نورون زیر نورون هایی هستند که روش STA برای آن ها جوابی قابل قبول (بالای ۶۰ درصد) داده است:

بهترین نتیجه برای نورون 010718.B.c01 با ۷۰ درصد تشخیص درست اسپایک ها به دست آمد.



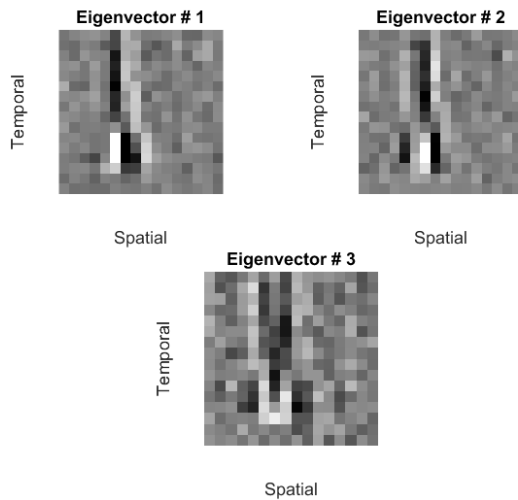


۴۹	<p>020214.A.j01 STA</p>  <p>Temporal</p> <p>Spatial</p> <p>High Contrast</p> <p>T Test 1 - PValue</p> <p>Temporal</p> <p>Spatial</p>	<p>020214.A.j01</p>  <p>spike</p> <p>control</p>	64.6146%
۴۲	<p>011025.A.d07 STA</p>  <p>Temporal</p> <p>Spatial</p> <p>High Contrast</p> <p>T Test 1 - PValue</p> <p>Temporal</p> <p>Spatial</p>	<p>011025.A.d07</p>  <p>spike</p> <p>control</p>	66.8326%
۳۷	<p>010718.B.c01 STA</p>  <p>Temporal</p> <p>Spatial</p> <p>High Contrast</p> <p>T Test 1 - PValue</p> <p>Temporal</p> <p>Spatial</p>	<p>010718.B.c01</p>  <p>spike</p> <p>control</p>	70.4846%
۳۱	<p>010322.A.f06 STA</p>  <p>Temporal</p> <p>Spatial</p> <p>High Contrast</p> <p>T Test 1 - PValue</p> <p>Temporal</p> <p>Spatial</p>	<p>010322.A.f06</p>  <p>spike</p> <p>control</p>	60.7857%

## بخش چهارم – بررسی با روش Spike- Triggered Correlation

در ابتدا بررسی‌های خود را روی نورون 000601.c05 که در بخش قبل نیز آن را انتخاب کردیم انجام می‌دهیم و در سوال آخر این بخش، روش خود را بر روی دیگر نورون‌ها تکرار کرده و نتایج را گزارش می‌کنیم.

### سوال ۱



ماتریس Spike-Triggered Correlation را برای این نورون حساب کرده و بردارهای ویژه مقادیر ویژه آن را محاسبه می‌کنیم. سه تصویر روبرو سه بردار ویژه مربوط به سه مقدار ویژه بزرگ این نورن هستند. برای تولید این تصاویر کانترست زیاد شده تا وضوح بالاتر برود.

### سوال ۲

به نظر ما روش زیر روش مناسبی است ولی نتوانستیم جواب قابل قبولی از آن بگیریم.

شکل ۸

یک بار برای تحریک‌های منجر به اسپایک ماتریس کوریلیشن را به دست می‌آوریم. هر عنصر بردار تحریک را یک متغیر تصادفی می‌گیریم پس ۲۵۶ متغیر تصادفی داریم که برای هر یک به تعداد دفعات انجام آزمایش نمونه داریم. با استفاده از این داده‌ها ماتریس کوریلیشن را که یک ماتریس ۲۵۶\*۲۵۶ است محاسبه می‌کنیم.

$$C_{mn} = \frac{1}{N} \sum_{i=1}^N S_m(i) S_n(i)$$

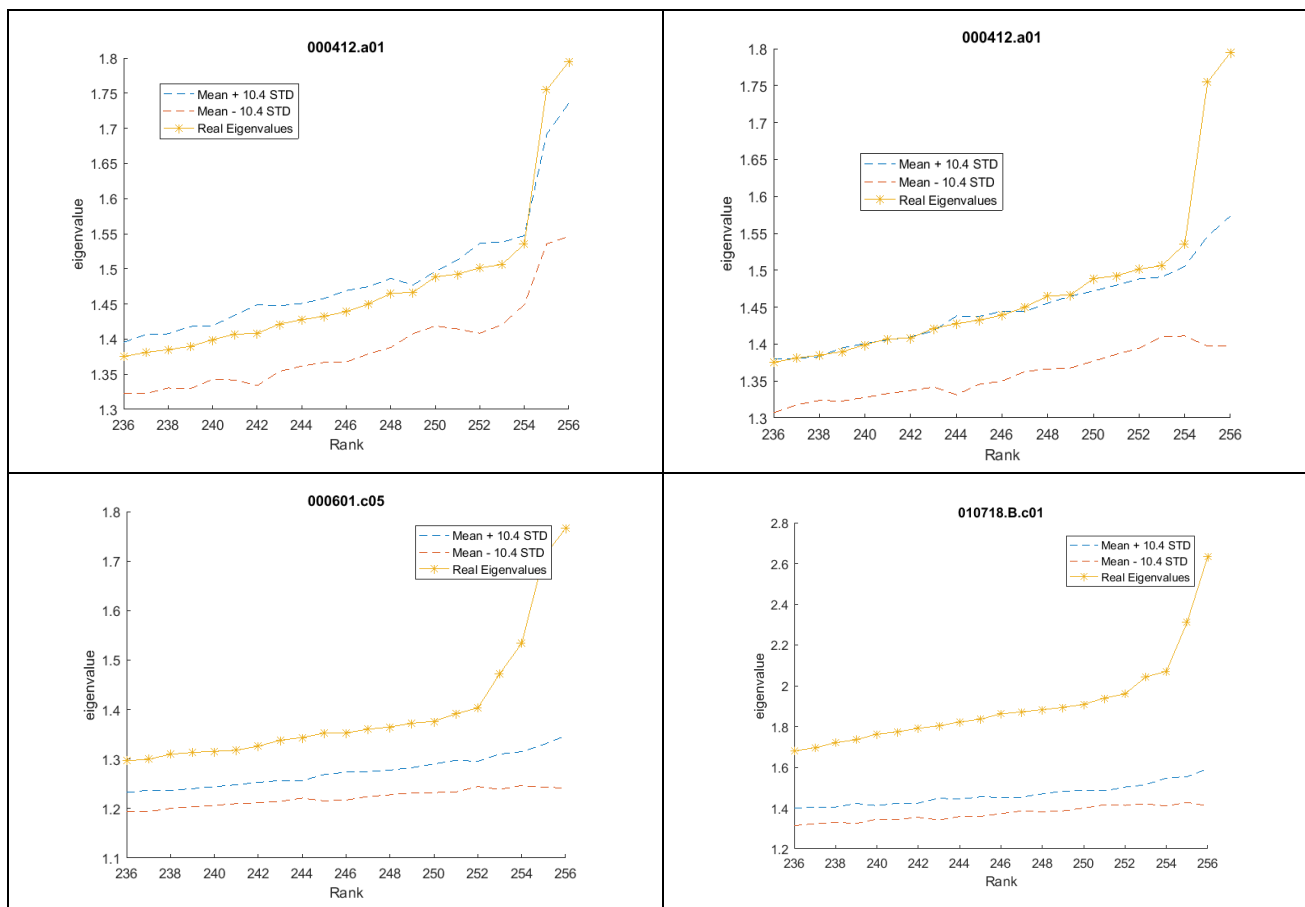
در این رابطه  $m$  و  $n$  اعدادی بین ۱ تا ۲۵۶ بوده و نماینده شماره عنصر ماتریس تحریک هستند.  $N$  تعداد کل دفعات انجام آزمایش است.  $S_m$  متغیر تصادفی  $m$  ام یعنی عنصر شماره  $m$  در بردار ۲۵۶ بعدی تحریک است.

حال قصد داریم بعد مساله را کاهش بدهیم تا آنالیزمان راحت تر شود برای این کار از روش PCA که در کلاس تمرین بحث شد استفاده می‌کنیم. بردارهای ویژه و مقادیر ویژه ماتریس کوریلیشن را به دست می‌آوریم و مقادیر ویژه را از کوچک به بزرگ مرتب می‌کنیم. نشان دادیم هر مقادیر ویژه برابر واریانس تصویر داده‌ها بر روی بردار ویژه مربوطه است. در این مساله می‌خواهیم مقادیر ویژه‌ای که به طرز معنا دار با بقیه تفاوت دارند را به دست بیاوریم و داده‌ها را تنها در جهت بردار ویژه‌های مربوط به آن تصویر کنیم تا بعد مساله را کاهش بدهیم و باز هم بتوانیم داده‌ها را جدا کنیم.

برای هر نورون، بیست سری زمان رندوم اسپایک به طول تعداد اسپایک‌های واقعی تولید می‌کنیم. برای این بیست سری زمان، بیست ماتریس کوریلیشن تولید می‌کنیم. بیست سری مقدار ویژه برای آنها به دست می‌آوریم و آنها را به ترتیب سورت می‌کنیم. میانگین و انحراف معیار را برای بزرگترین مقادیر ویژه، دومین مقدار ویژه بزرگ و ... محاسبه می‌کنیم. بازه اطمینان برای  $i$  امین مقدار ویژه بزرگ را بازه زیر می‌گیریم:

میانگین مقدار ویژه‌های  $i$  ام ماتریس‌های کنترل  $\pm 10.4$  برابر انحراف معیار مقدار ویژه‌های  $i$  ام ماتریس‌های کنترل

این روش برای بعضی نورون‌ها جواب نمی‌دهد و تعداد بسیار زیادی از مقادیر ویژه خارج از این بازه قرار می‌گیرند.



شکل ۹

به وضوح دیده می‌شود این روش برای بعضی از نورون‌ها جواب نمی‌دهد.

متأسفانه نویسندگان مقاله نحوه محاسبه بازه اطمینان رو به طور واضح توضیح نداده‌اند. ما نیز به نویسندگان در این رابطه ایمیل زدیم ولی ایده آنها برای حل

مساله ما کارساز نبود.



Touryan, Jonathan O CIV USARMY RDECOM ARL (US) <jonathan.o.touryan.civ@mail.mil>

Today, 6:36 PM

You

Reply

Behrad,

Obviously, it's been a long time since I've worked with this data so I can only give you some general suggestions. Considering your issue, it seems like there is a mismatch between the total variance of the spike triggered and control covariance matrices. I would look for a normalization method (e.g. z-score) such the total variance is preserved (i.e. sum of the eigenvalues). The purpose of this test is to compare eigenvalues from random versus structured distributions of the same mean and variance.

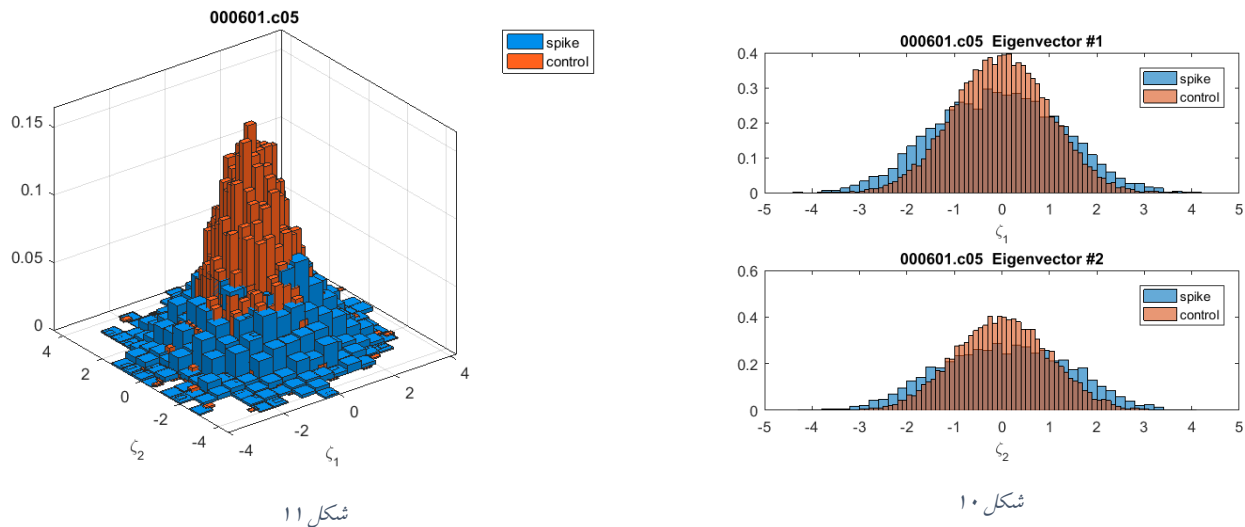
Good luck,

- Jon

در سوال دو ما سه بردار به عنوان Receptive Field نورو به دست آوردیم. با توجه به این نتایج، نورو مورد استفاده ما این موضوع که نواری مشکی بین دو نوار سفید برای مدتی باقی بماند و یا یک نوار سفید بین دو نوار مشکی برای مدتی باقی بماند را تشخیص می‌دهد. در دو بردار ویژه اول این پترن‌های معنا دار دیده می‌شود در حالی که در بردار ویژه سوم این پترن معنا دار تا حدودی از بین رفته است.

به نظر باید برای هر نورو تنها بردارهای ویژه با پترن معنادار را انتخاب کنیم و تصویر تحریک‌ها را بر روی آنها در نظر بگیریم و بعد فضای خود را تا تعداد این بردار ویژه‌ها پایین بیاوریم.

توزیع تصویر بردارهای تحریک روی دو بردار ویژه اول و همچنین توزیع joint تصویر بردارهای تحریک بر روی دو بردار ویژه اول را برای نورو انتخاب شده رسم می‌کنیم. شکل ۱۰ و ۱۱.



فرض کنید  $N$  بردار ویژه با اهمیت داشته باشیم و تصویر تحریک‌های منجر به اسپایک بر روی هر یک را  $\zeta_n$  بنامیم و تصویر تحریک‌های کنترل را  $\zeta_{nR}$ . توزیع joint را برای  $\zeta_n$  ها و  $\zeta_{nR}$  به دست می‌آوریم. حال برای تشخیص اینکه یک تحریک خاص منجر به اسپایک می‌شود یا نه، تحریک مربوط به آن را روی بردارهای ویژه با اهمیت تصویر می‌کنیم و یک بردار  $N$  بعدی به دست می‌آوریم. مقدار pdf توزیع زتای رندوم و زتا را در این نقطه حساب می‌کنیم. اگر مقدار مربوط به زتای رندوم بیشتر از مقدار زتا بود، می‌گوییم اسپایک رخ نخواهد داد و اگر برعکس بود، می‌گوییم این تحریک منجر به اسپایک می‌شود.

همان طور که در سوال سه مطرح شد، نویسندگان روش خود برای بررسی این موضوع که کدام ویژگی مقدارها Significant هستند و خارج محدوده اطمینان قرار می‌گیرند را صریح بیان نکرده‌اند. ما چند روش را برای گرفتن نتیجه امتحان کردیم:

- تنها بردار ویژه برای هر نورون
- تنها سه بردار ویژه برای هر نورون

در بررسی‌ای که ما انجام می‌دهیم روش دوم درصد تشخیص اسپایک بالاتری نسبت به روش اول دارد اما این به خاطر این است که ما ماشین را با همان داده‌هایی می‌سنجیم که با آن به او آموزش دادیم. اگر تعدادی تحریک جدید به ما داده شود احتمال دارد به دلیل توجه بیش از اندازه ما به داده‌ها در روش دوم Over Fitting اتفاق بی‌افتد و از دقت کارمان کاسته شود چون توجه زیادی به داده‌های پرت و نویز نیز کرده‌ایم.

برای نورون انتخاب شده در این بخش توانستیم 53.33 درصد اسپایک‌ها را درست تشخیص دهیم.

## سوال ۵

جدول خواسته شده به دلیل حجم بالا در این فایل نیامده بلکه به طور پیوست در فایل *STC.pdf* ارسال شده است.

## سوال ۶

در این روش، در تمام نورون‌ها، بردار ویژه‌های اول و دوم پترن‌های معناداری دیده می‌شود اما اکثراً بردار ویژه سوم پترن معناداری ندارد. یک مزیت این روش نسبت به روش STA نیز همین است که تنها به یک جهت نگاه نمی‌کند بلکه به دو یا سه جهت اهمیت می‌دهد.

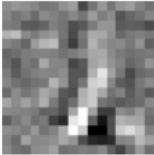
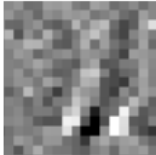
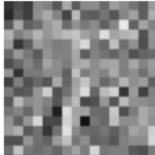

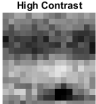
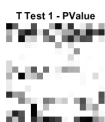
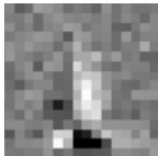
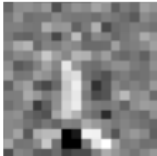
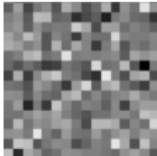


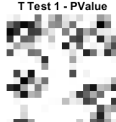
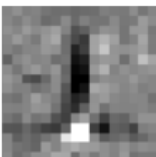
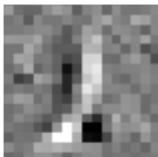
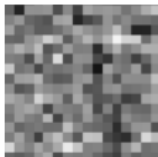

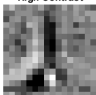

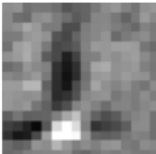
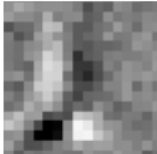
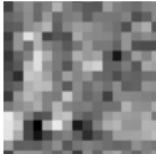
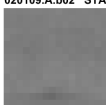
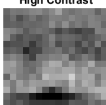
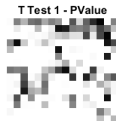
به جدول ۲ در صفحه بعد مراجعه کنید. در این جدول برای چهار نورون دلخواه، سه بردار ویژه اول و STA مقایسه شده‌اند.

در مورد برخی نورون‌ها، روش STA قدرت پیش‌بینی اسپایک بیشتری داشت. این متلب با شهود ناسازگاری دارد زیرا انتظار داریم اگر برای نورونی روش STA جواب دقیقی می‌دهد، روش PCA هم حداقل بتواند این جواب را تکرار کند. در بخش پنجم به این موضوع نیز خواهیم پرداخت.

یک علت این مشاهده می‌تواند این باشد که زمان‌های رندوم ما ممکن است با زمان اسپایک یکسان باشد و ممکن است اشتراک داشته باشند. احتمال این موضوع صفر نیست چون تحریک ما فریم فریم است و در واقع مثل این است که زمان ما پیوسته نیست.

نکته بسیار جالبی نیز در این داده‌ها وجود دارد. اگر STA جواب بسیار مناسبی برای یک نورون باشد. بردار ویژه‌های اول ماتریس کورریلیشن نیز بسیار شبیه به STA خواهند شد و Spike Triggered Correlation هم تخمین بسیار خوبی از عملکرد نورون خواهد زد.

به عنوان مثال به سطر رنگی جدول صفحه آینده توجه کنید. برای نورون این سطر روش STA در ۷۰ درصد مواقع اسپایک را به درستی تشخیص می‌داد. بردار ویژه غالب این نورون با تقریب بسیار بسیار خوبی همان بردار STA این نورون است.

سه بردار ویژه اول	روش STA
<div><div>000824.g04 # 1</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>000824.g04 # 2</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>000824.g04 # 3</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>	<div><div>000824.g04 STA</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>High Contrast</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>T Test 1 - PValue</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>
<div><div>010718.B.c01 # 1</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>010718.B.c01 # 2</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>010718.B.c01 # 3</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>	<div><div>010718.B.c01 STA</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>High Contrast</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>T Test 1 - PValue</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>
<div><div>020109.A.b01 # 1</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>020109.A.b01 # 2</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>020109.A.b01 # 3</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>	<div><div>020109.A.b01 STA</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>High Contrast</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>T Test 1 - PValue</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>
<div><div>020109.A.b02 # 1</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>020109.A.b02 # 2</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>020109.A.b02 # 3</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>	<div><div>020109.A.b02 STA</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>High Contrast</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div> <div><div>T Test 1 - PValue</div><div><div>Temporal</div><div></div><div>Spatial</div></div></div>

جدول ۲

## بخش پنجم – چند سوال دلخواه!

در این بخش چند سوال که به نظر ما جالب بود را مطرح و بررسی کردیم.

### • سوال اول

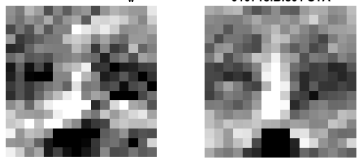
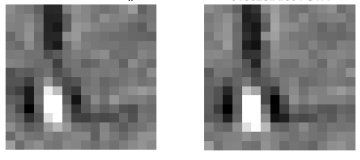
در کلاس درس دیدیم که اگر تحریکمان نویز سفید نباشد و autocorrelation غیر دلتا داشته باشد، روش STA یک تخمین بایاس شده از فیلتر به ما می‌دهد.


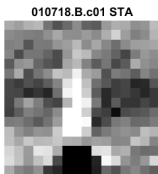


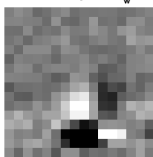
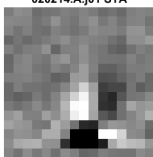
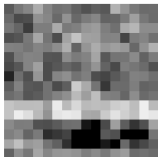
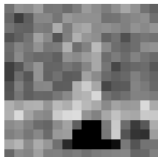
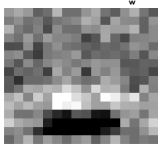

برای برطرف کردن این موضوع پیشنهاد شده است که به جای استفاده از STA، از بردار زیر استفاده کنیم. این روش تنها زمانی کارساز است که تحریکمان را بتوان با یک توزیع گاوسی توصیف کرد.

$$STA_w = \left( \frac{1}{N} \sum_{i=1}^N x_i x_i^T \right)^{-1} \frac{1}{\Sigma} \sum_{i=1}^N r_i x_i$$


یعنی معکوس ماتریس کوواریانس را در STA ضرب کرده و به عنوان بردار STA سفید شده (!) معرفی می‌کنیم. این رابطه برای نویز سفید همان STA معمولی است. به جای میانگین‌گیری ساده نیز از میانگین با وزن spike count rate برای هر تحریک منجر به اسپایک استفاده شده است.

بخش سوم تمرین را مجدداً با این بردار تکرار کرده و نتایج را مقایسه می‌کنیم. در جدول زیر درصد پیشبینی درست اسپایک روش‌های STA و روش سفید شده STA برای چند نورون خاص مقایسه شده‌اند. مشاهده می‌شود که درصد تشخیص بسیار بهتر شده است و این روش به مراتب روش بهتری از STA است.

نام نورون	Rec Field	STAw Percent	STA Percent
000511.b09		%۶۶/۸۸۱۱	%۴۷/۱۲۱۷
010628.A.c04		%۶۷/۷۶۴۱	%۵۵/۳۶۹۶

۷۰/۲۹۵۸%	۷۴/۸۴۷۹%	 	010718.B.c01
۶۶/۰۸۵۸%	۶۹/۵۳۲۷%	 	011025.A.d07
۶۴/۲۸۲۸%	۶۶/۱۴۹۲%	 	020214.A.j01
۵۳/۱۲۵%	۶۵/۶۱۴۱%	 	020306.A.a01
۶۳/۵۵۷۸%	۶۹/۶۰۴۷%	 	020306.A.a02





شکل ۱۲

شکل ۱۲ نمودار درصد تشخیص درست اسپایک برای روش سفید شده STA بر حسب درصد تشخیص درست اسپایک برای روش معمولی STA است. افزایش چشمگیری قابل مشاهده است.

یک ایده دیگر نیز این است که تنها اسپایک‌هایی را در نظر بگیریم که حداقل چند اسپایک در نزدیکی آن وجود داشته باشد اما این کار باعث می‌شود دیتای بسیار زیادی را از دست بدهیم و به نظر من امکان از دست دادن اسپایک‌های مفید در آن زیاد است. در روش ما تا حدی به دلیل میانگین وزن‌دار با وزن نرخ اسپایک زنی این موضوع عملی می‌شود اما حذف کامل اسپایک‌های دورافتاده شاید کار دقیقی نباشد.

#### • سوال دوم

دیده می‌شود که بعضاً روش STA بهتر از روش Spike Triggered Correlation عمل کرده‌است. می‌خواهیم کمی این موضوع را کالبدشکافی کنیم! برای این کار به جای استفاده از تنها دو یا سه بردار ویژه خاص و تصویر تحریک‌ها بر روی این بردارهای ویژه، تصویر تحریک‌ها را بر تمام بردارهای ویژه به دست می‌آوریم. تصاویر را Jointly Gaussian در نظر می‌گیریم و تصویر روی جهت‌های مختلف را مستقل فرض نمی‌کنیم. توزیع تصویر تحریک‌های منجر به اسپایک و توزیع تصویر تحریک‌های مربوط به زمان‌های رندوم را

$$f_X(x) = (2\pi \det \Sigma)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right) \quad \text{به دست می‌آوریم.}$$

در آخر برای حدس زدن اینکه یک تحریک منجر به اسپایک می‌شود یا نه، از همان روش مقایسه مقدار دو pdf مذکور در آن نقطه که در بخش‌های قبل بحث شد استفاده می‌کنیم.

همین روش را یک بار دیگر نیز تکرار می‌کنیم با این تفاوت که به جای استفاده از بردارهای ویژه از بردارهای یکه استاندارد استفاده کنیم. به دلیل حجم محاسبات بالای این روش جدید، آن را برای ۵ نورون پیاده می‌کنیم و نتایج این روش و روش‌های دیگر سوال را در یک جدول می‌آوریم.

در جدول زیر دیده می‌شود که روش تصویر کردن بر روی ۲۵۶ بردار ویژه از دیگر روش‌ها بهتر جواب داده اما این کار لزوماً کار درستی نیست زیرا ممکن است به مشکل overfitting منجر شود. به طور مثال در شکل ۱۲ یک بار از داده‌ها خط عبور داده شده و یک بار از داده‌های یک چندجمله‌ای مرتبه بالای درونیاب. به نظر می‌رسد چندجمله‌ای به دلیل توجه بیش از حد به داده‌ها، از نویز تاثیر فراوان و مخرب تری از خط گرفته است.

جدول ۴

نورون	STA	Spike Trig. Corr.	256 Eigen Vecs	Standard Basis
000412.a01	54.076	51.805	57.667	57.531
000601.c05	54.176	53.702	56.762	56.875
010628.A.c04	55.369	44.516	63.031	62.73
020306.A.a01	53.125	49.946	64.199	63.654
000914.c07	53.744	49.014	57.203	57.835
000622.f05	52.336	51.714	58.399	58.14